Práctica 1: Importación de datos.

Análisis Exploratorio de Datos. Máster en Ciencia de Datos - UV

Javier Rodríguez Jiménez

2026-10-20

Índice

1. Lectura del fichero DFP1_11122015 124700.csv **1**

1.1. Importación del fichero 1

1.2. Importación del fichero 2

2. Transactions from a Bakery (Kaggle) **2**

3. Lectura de SPSS PsychBike.sav **3**

4. Fichero data iris.zip **4**

4.1. Importación del fichero 5

4.2. Inspección de los datos 5

5. Fichero JSON FileCodificado.json **5**

5.1. Inspección de los datos 5

1. Lectura del fichero DFP1_11122015 124700.csv

1.1. Importación del fichero

La diferencia entre importar con readr y base es que en readr te permite seleccionar el tipo de variable que es cada columna. Por otro lado, en base reconoció automáticamente que la separación es de tipo tabulador mientras que en readr no ocurrió lo mismo. Pero en cuanto a contenido y cómo importa el contenido, no hay diferencia.

Ahora importamos el fichero **DFP1_11122015 124700.csv** con read.csv

Convertimos a fecha y hora cargando la librería

1.2. Importación del fichero

```
'data.frame':   8887 obs. of  5 variables:
 $ FECHA            : POSIXlt, format: "2015-12-11" "2015-12-11" "2015-12-11" ...
 $ HORA             : 'hms' num  12:47:02 12:47:02 12:47:02 12:47:03 ...
  ..- attr(*, "units")= chr "secs"
 $ Altura           : num  138 138 138 138 138 ...
 $ Combinacion_Canya: num  2 2 2 2 2 2 2 2 2 2 ...
 $ Temperatura      : num  14.6 14.6 14.6 14.6 14.6 14.6 14.6 14.6 14.6 14.6 ...
```

Vemos las características principales del contenido de nuestros datos como el nombre de las variables, número de observaciones, tipo de variables, etc.

```
       FECHA     HORA Altura Combinacion_Canya Temperatura
1 2015-12-11 12:47:02 137.81                 2        14.6
2 2015-12-11 12:47:02 137.81                 2        14.6
3 2015-12-11 12:47:02 137.81                 2        14.6
4 2015-12-11 12:47:03 137.81                 2        14.6
5 2015-12-11 12:47:03 137.81                 2        14.6
6 2015-12-11 12:47:03 137.81                 2        14.6
```

```
          FECHA     HORA Altura Combinacion_Canya Temperatura
8882 2015-12-11 13:49:41 949.13                 2        14.7
8883 2015-12-11 13:49:41 949.13                 2        14.7
8884 2015-12-11 13:49:41 949.13                 2        14.7
8885 2015-12-11 13:49:41 949.13                 2        14.7
8886 2015-12-11 13:49:41 949.13                 2        14.7
8887 2015-12-11 13:49:42 949.13                 2        14.7
```

Vemos las primeras observaciones y las últimas.

```
     FECHA                    HORA          Altura       Combinacion_Canya  Temperatura
 Min.   :2015-12-11   Length   :8887   Min.   : 137.8   Min.   :1         Min.   :14.40
 1st Qu.:2015-12-11   N.unique :1898   1st Qu.: 400.9   1st Qu.:1         1st Qu.:14.50
 Median :2015-12-11   N.blank  :   0   Median : 953.1   Median :2         Median :14.60
 Mean   :2015-12-11   Min.nchar:   8   Mean   : 785.8   Mean   :2         Mean   :14.57
 3rd Qu.:2015-12-11   Max.nchar:   8   3rd Qu.:1079.0   3rd Qu.:3         3rd Qu.:14.60
 Max.   :2015-12-11                    Max.   :1089.1   Max.   :3         Max.   :14.70
```

Nos da un resumen estadístico de cada variable

2. Transactions from a Bakery (Kaggle)

Leemos los datos con readr especificando con dato tipo fecha

```
spc_tbl_ [20,507 x 5] (S3: spec_tbl_df/tbl_df/tbl/data.frame)
 $ Transaction    : num [1:20507] 1 2 2 3 3 3 4 5 5 5 ...
 $ Item           : chr [1:20507] "Bread" "Scandinavian" "Scandinavian" "Hot chocolate" ...
 $ date_time      : POSIXct[1:20507], format: "2016-10-30 09:58:00" "2016-10-30 10:05:00" "2016-10-30 10
 $ period_day     : chr [1:20507] "morning" "morning" "morning" "morning" ...
 $ weekday_weekend: chr [1:20507] "weekend" "weekend" "weekend" "weekend" ...
```

```
 - attr(*, "spec")=
  .. cols(
  ..   Transaction = col_double(),
  ..   Item = col_character(),
  ..   date_time = col_datetime(format = "%m/%d/%Y %H:%M"),
  ..   period_day = col_character(),
  ..   weekday_weekend = col_character()
  .. )
 - attr(*, "problems")=<pointer: 0x10e623660>
```

```
  Transaction          Item         date_time                     period_day     weekday_weekend
 Min.   :   1   Length   :20507   Min.   :2016-10-30 09:58:00   Length   :20507   Length   :20507
 1st Qu.:2552   N.unique :   94   1st Qu.:2016-12-03 14:28:00   N.unique :    4   N.unique :    2
 Median :5137   N.blank  :    0   Median :2017-01-22 11:18:00   N.blank  :    0   N.blank  :    0
 Mean   :4976   Min.nchar:    3   Mean   :2017-01-18 01:31:08   Min.nchar:    5   Min.nchar:    7
 3rd Qu.:7357   Max.nchar:   29   3rd Qu.:2017-02-28 16:00:00   Max.nchar:    9   Max.nchar:    7
 Max.   :9684                     Max.   :2017-04-09 15:04:00
```

```
# A tibble: 6 x 5
  Transaction Item          date_time           period_day weekday_weekend
        <dbl> <chr>         <dttm>              <chr>      <chr>
1           1 Bread         2016-10-30 09:58:00 morning    weekend
2           2 Scandinavian  2016-10-30 10:05:00 morning    weekend
3           2 Scandinavian  2016-10-30 10:05:00 morning    weekend
4           3 Hot chocolate 2016-10-30 10:07:00 morning    weekend
5           3 Jam           2016-10-30 10:07:00 morning    weekend
6           3 Cookies       2016-10-30 10:07:00 morning    weekend
```

```
# A tibble: 6 x 5
  Transaction Item         date_time           period_day weekday_weekend
        <dbl> <chr>        <dttm>              <chr>      <chr>
1        9682 Tacos-Fajita 2017-04-09 14:32:00 afternoon  weekend
2        9682 Coffee       2017-04-09 14:32:00 afternoon  weekend
3        9682 Tea          2017-04-09 14:32:00 afternoon  weekend
4        9683 Coffee       2017-04-09 14:57:00 afternoon  weekend
5        9683 Pastry       2017-04-09 14:57:00 afternoon  weekend
6        9684 Smoothies    2017-04-09 15:04:00 afternoon  weekend
```

3. Lectura de SPSS PsychBike.sav

```
tibble [2,355 x 6] (S3: tbl_df/tbl/data.frame)
 $ vehicle           : dbl+lbl [1:2355] 1, 5, 2, 1, 4, 1, 2, 1, 4, 7, 2, 3, 1, 1, 1, 2, 1, 2, 1, 1, 1, 1
   ..@ format.spss: chr "F11.0"
   ..@ labels     : Named num [1:7] 1 2 3 4 5 6 7
   .. ..- attr(*, "names")= chr [1:7] "car" "LGV" "SUV" "bus" ...
 $ Colour            : dbl+lbl [1:2355]  1,  2,  1, 99,  9,  3,  4,  2,  2, 99,  4,  4,  1,  1,  1,  4,
   ..@ format.spss: chr "F11.0"
   ..@ labels     : Named num [1:8] 1 2 3 4 5 6 9 99
   .. ..- attr(*, "names")= chr [1:8] "blue" "red" "silver/grey" "white" ...
 $ hour              : 'hms' num [1:2355] 16:00:00 16:00:00 16:00:00 16:00:00 ...
  ..- attr(*, "units")= chr "secs"
  ..- attr(*, "format.spss")= chr "TIME11.2"
```

```
 $ helmet            : num [1:2355] 0 0 0 0 0 0 1 1 1 1 ...
  ..- attr(*, "format.spss")= chr "F11.0"
 $ Distance_from_kerb: num [1:2355] 0.5 0.5 0.5 0.5 0.5 0.5 1 1 1 1 ...
  ..- attr(*, "label")= chr "Distance from kerb"
  ..- attr(*, "format.spss")= chr "F11.1"
 $ Passing_distance  : num [1:2355] 1.864 0.748 1.567 1.39 1.294 ...
  ..- attr(*, "label")= chr "Passing distance"
  ..- attr(*, "format.spss")= chr "F11.3"
```

```
# A tibble: 6 x 6
  vehicle   Colour           hour   helmet Distance_from_kerb Passing_distance
  <dbl+lbl> <dbl+lbl>        <time>  <dbl>              <dbl>            <dbl>
1 1 [car]    1 [blue]        16:00       0                0.5            1.86
2 5 [HGV]    2 [red]         16:00       0                0.5            0.748
3 2 [LGV]    1 [blue]        16:00       0                0.5            1.57
4 1 [car]   99 [unknown]     16:00       0                0.5            1.39
5 4 [bus]    9 [other]       16:00       0                0.5            1.29
6 1 [car]    3 [silver/grey] 16:00       0                0.5            1.26
```

```
# A tibble: 6 x 6
  vehicle   Colour          hour   helmet Distance_from_kerb Passing_distance
  <dbl+lbl> <dbl+lbl>       <time>  <dbl>              <dbl>            <dbl>
1 2 [LGV]   9 [other]       10:00       1               1.25            1.10
2 1 [car]   3 [silver/grey] 10:00       1               1.25            1.01
3 1 [car]   2 [red]         10:00       1               1.25            0.922
4 5 [HGV]   4 [white]       10:00       1               1.25            0.564
5 1 [car]   1 [blue]        10:00       1               1.25            0.65
6 1 [car]   6 [green]       10:00       1               1.25            0.781
```

```
    vehicle          Colour              hour          helmet       Distance_from_kerb
 Min.   :1.000   Min.   : 1.000   Length   :2355   Min.   :0.0000   Min.   :0.2500
 1st Qu.:1.000   1st Qu.: 1.000   N.unique :  11   1st Qu.:0.0000   1st Qu.:0.2500
 Median :1.000   Median : 3.000   N.blank  :   0   Median :0.0000   Median :0.5000
 Mean   :1.634   Mean   : 3.556   Min.nchar:  15   Mean   :0.4879   Mean   :0.6702
 3rd Qu.:2.000   3rd Qu.: 4.000   Max.nchar:  15   3rd Qu.:1.0000   3rd Qu.:1.0000
 Max.   :7.000   Max.   :99.000                    Max.   :1.0000   Max.   :1.2500
 Passing_distance
 Min.   :0.144
 1st Qu.:1.053
 Median :1.279
 Mean   :1.314
 3rd Qu.:1.540
 Max.   :3.537
```

4. Fichero data iris.zip

Descargamos y los ubicamos en la carpeta data

4.1. Importación del fichero

4.2. Inspección de los datos

```
'data.frame':   150 obs. of  5 variables:
 $ sepal_length: num  5.1 4.9 4.7 4.6 5 5.4 4.6 5 4.4 4.9 ...
 $ sepal_length: num  3.5 3 3.2 3.1 3.6 3.9 3.4 3.4 2.9 3.1 ...
 $ petal_length: num  1.4 1.4 1.3 1.5 1.4 1.7 1.4 1.5 1.4 1.5 ...
 $ petal_length: num  0.2 0.2 0.2 0.2 0.2 0.4 0.3 0.2 0.2 0.1 ...
 $ NA          : chr  "Iris-setosa" "Iris-setosa" "Iris-setosa" "Iris-setosa" ...
```

```
  sepal_length sepal_length petal_length petal_length        <NA>
1          5.1          3.5          1.4          0.2 Iris-setosa
2          4.9          3.0          1.4          0.2 Iris-setosa
3          4.7          3.2          1.3          0.2 Iris-setosa
4          4.6          3.1          1.5          0.2 Iris-setosa
5          5.0          3.6          1.4          0.2 Iris-setosa
6          5.4          3.9          1.7          0.4 Iris-setosa
```

```
    sepal_length sepal_length petal_length petal_length           <NA>
145          6.7          3.3          5.7          2.5 Iris-virginica
146          6.7          3.0          5.2          2.3 Iris-virginica
147          6.3          2.5          5.0          1.9 Iris-virginica
148          6.5          3.0          5.2          2.0 Iris-virginica
149          6.2          3.4          5.4          2.3 Iris-virginica
150          5.9          3.0          5.1          1.8 Iris-virginica
```

```
  sepal_length    sepal_length    petal_length    petal_length           NA
 Min.   :4.300   Min.   :2.000   Min.   :1.000   Min.   :0.100   Length   :150
 1st Qu.:5.100   1st Qu.:2.800   1st Qu.:1.600   1st Qu.:0.300   N.unique :  3
 Median :5.800   Median :3.000   Median :4.350   Median :1.300   N.blank  :  0
 Mean   :5.843   Mean   :3.054   Mean   :3.759   Mean   :1.199   Min.nchar: 11
 3rd Qu.:6.400   3rd Qu.:3.300   3rd Qu.:5.100   3rd Qu.:1.800   Max.nchar: 15
 Max.   :7.900   Max.   :4.400   Max.   :6.900   Max.   :2.500
```

5. Fichero JSON FileCodificado.json

Cargamos la librería

5.1. Inspección de los datos

```
'data.frame':   83 obs. of  22 variables:
 $ Carburante             : int  1 1 1 1 1 1 1 1 1 1 ...
 $ Potencia               : int  60 60 60 60 60 60 60 60 60 60 ...
 $ Servicio_Vehiculo      : chr  "B00" "B00" "B00" "B00" ...
 $ Actividad_Vehiculo     : chr  "D" "D" "D" "D" ...
 $ GAMA                   : chr  "UTILITARIO" "UTILITARIO" "UTILITARIO" "UTILITARIO" ...
 $ Unidades_Matriculadas  : int  0 0 0 0 0 0 0 0 0 0 ...
 $ Localidad_definitiva   : chr  "ALGECIRAS" "ALGECIRAS" "ALGECIRAS" "ALGECIRAS" ...
 $ Provincia_definitiva   : chr  "CADIZ" "CADIZ" "CADIZ" "CADIZ" ...
 $ Codigo_Postal          : num  0.0297 0.0297 0.0297 0.0297 0.0297 0.0297 0.0297 0.0297 0.0297 0.0297
```

```
 $ Viviendas              : num  0.12 0.12 0.12 0.12 0.12 ...
 $ precio_medio_m2        : num  0.18 0.18 0.18 0.18 0.18 ...
 $ Peso_vivienda          : int  2 2 2 2 2 2 2 2 2 2 ...
 $ RAISON_SOCIAL          : chr  "ALGECIREÑA DE MOTOR E INV., S.L." "ALGECIREÑA DE MOTOR E INV., S.L." "
 $ RUE_SSOC               : chr  "Ctra. a Malaga, Km. 108" "Ctra. a Malaga, Km. 108" "Ctra. a Malaga, Kr
 $ Edad_Conductor         : chr  "18 a 20 años" "21 a 24 años" "25 a 29 años" "30 a 34 años" ...
 $ Numero de Conductores  : num  0.0132 0.0569 0.1086 0.1392 0.1706 ...
 $ Antigüedad             : int  0 0 0 0 0 0 0 0 0 0 ...
 $ Anos_Antiguedad        : int  0 0 0 0 0 0 0 0 0 0 ...
 $ Numero_vehiculos_parque: int  0 0 0 0 0 0 0 0 0 0 ...
 $ Cluster_GamaPotencia   : chr  "cluster_1_GamaPotencia" "cluster_1_GamaPotencia" "cluster_1_GamaPoten
 $ Cluster_Antiguedad     : chr  "cluster_1_Antiguedad" "cluster_1_Antiguedad" "cluster_1_Antiguedad" "
 $ Cluster_Edad           : chr  "cluster_3_Edad" "cluster_3_Edad" "cluster_3_Edad" "cluster_3_Edad" ..
```

```
  Carburante Potencia Servicio_Vehiculo Actividad_Vehiculo       GAMA Unidades_Matriculadas
1          1       60               B00                  D UTILITARIO                    0
2          1       60               B00                  D UTILITARIO                    0
3          1       60               B00                  D UTILITARIO                    0
4          1       60               B00                  D UTILITARIO                    0
5          1       60               B00                  D UTILITARIO                    0
6          1       60               B00                  D UTILITARIO                    0
  Localidad_definitiva Provincia_definitiva Codigo_Postal Viviendas precio_medio_m2 Peso_vivienda
1            ALGECIRAS                CADIZ        0.0297    0.1201          0.1799             2
2            ALGECIRAS                CADIZ        0.0297    0.1201          0.1799             2
3            ALGECIRAS                CADIZ        0.0297    0.1201          0.1799             2
4            ALGECIRAS                CADIZ        0.0297    0.1201          0.1799             2
5            ALGECIRAS                CADIZ        0.0297    0.1201          0.1799             2
6            ALGECIRAS                CADIZ        0.0297    0.1201          0.1799             2
                    RAISON_SOCIAL               RUE_SSOC Edad_Conductor Numero de Conductores
1 ALGECIREÑA DE MOTOR E INV., S.L. Ctra. a Malaga, Km. 108   18 a 20 años                0.0132
2 ALGECIREÑA DE MOTOR E INV., S.L. Ctra. a Malaga, Km. 108   21 a 24 años                0.0569
3 ALGECIREÑA DE MOTOR E INV., S.L. Ctra. a Malaga, Km. 108   25 a 29 años                0.1086
4 ALGECIREÑA DE MOTOR E INV., S.L. Ctra. a Malaga, Km. 108   30 a 34 años                0.1392
5 ALGECIREÑA DE MOTOR E INV., S.L. Ctra. a Malaga, Km. 108   35 a 39 años                0.1706
6 ALGECIREÑA DE MOTOR E INV., S.L. Ctra. a Malaga, Km. 108   40 a 44 años                0.1577
  Antigüedad Anos_Antiguedad Numero_vehiculos_parque   Cluster_GamaPotencia   Cluster_Antiguedad
1          0              0                       0 cluster_1_GamaPotencia cluster_1_Antiguedad
2          0              0                       0 cluster_1_GamaPotencia cluster_1_Antiguedad
3          0              0                       0 cluster_1_GamaPotencia cluster_1_Antiguedad
4          0              0                       0 cluster_1_GamaPotencia cluster_1_Antiguedad
5          0              0                       0 cluster_1_GamaPotencia cluster_1_Antiguedad
6          0              0                       0 cluster_1_GamaPotencia cluster_1_Antiguedad
    Cluster_Edad
1 cluster_3_Edad
2 cluster_3_Edad
3 cluster_3_Edad
4 cluster_3_Edad
5 cluster_3_Edad
6 cluster_3_Edad
```

```
   Carburante Potencia Servicio_Vehiculo Actividad_Vehiculo       GAMA Unidades_Matriculadas
78          1       60               B00                  D UTILITARIO                    0
79          1       60               B00                  D UTILITARIO                    0
80          1       60               B00                  D UTILITARIO                    0
```

```
81          1       60               B00                  D UTILITARIO                     0
82          1       60               B00                  D UTILITARIO                     0
83          1       60               B00                  D UTILITARIO                     0
     Localidad_definitiva Provincia_definitiva Codigo_Postal Viviendas precio_medio_m2
78 CHICLANA DE LA FRONTERA               CADIZ         0.028    0.1132          0.4255
79 CHICLANA DE LA FRONTERA               CADIZ         0.028    0.1132          0.4255
80 CHICLANA DE LA FRONTERA               CADIZ         0.028    0.1132          0.4255
81 CHICLANA DE LA FRONTERA               CADIZ         0.028    0.1132          0.4255
82 CHICLANA DE LA FRONTERA               CADIZ         0.028    0.1132          0.4255
83 CHICLANA DE LA FRONTERA               CADIZ         0.028    0.1132          0.4255
   Peso_vivienda          RAISON_SOCIAL                RUE_SSOC Edad_Conductor
78             3       RAMON HOYO, S.L. AVDA. REYES CATOLICOS, 5 Más de 74 años
79             3 TALLERES COLCHÓN, S.L.               Caraza, 33   18 a 20 años
80             3 TALLERES COLCHÓN, S.L.               Caraza, 33   21 a 24 años
81             3 TALLERES COLCHÓN, S.L.               Caraza, 33   25 a 29 años
82             3 TALLERES COLCHÓN, S.L.               Caraza, 33   30 a 34 años
83             3 TALLERES COLCHÓN, S.L.               Caraza, 33   35 a 39 años
   Numero de Conductores Antigüedad Anos_Antiguedad Numero_vehiculos_parque   Cluster_GamaPotencia
78                0.0098         0               0                       0 cluster_1_GamaPotencia
79                0.0099         0               0                       0 cluster_1_GamaPotencia
80                0.0321         0               0                       0 cluster_1_GamaPotencia
81                0.0793         0               0                       0 cluster_1_GamaPotencia
82                0.0946         0               0                       0 cluster_1_GamaPotencia
83                0.1150         0               0                       0 cluster_1_GamaPotencia
     Cluster_Antiguedad   Cluster_Edad
78 cluster_6_Antiguedad cluster_3_Edad
79 cluster_1_Antiguedad cluster_3_Edad
80 cluster_1_Antiguedad cluster_3_Edad
81 cluster_1_Antiguedad cluster_3_Edad
82 cluster_1_Antiguedad cluster_3_Edad
83 cluster_1_Antiguedad cluster_3_Edad


   Carburante    Potencia  Servicio_Vehiculo Actividad_Vehiculo        GAMA
 Min.   :1    Min.   :60   Length   :83      Length   :83       Length   :83
 1st Qu.:1    1st Qu.:60   N.unique : 1      N.unique : 1       N.unique : 1
 Median :1    Median :60   N.blank  : 0      N.blank  : 0       N.blank  : 0
 Mean   :1    Mean   :60   Min.nchar: 3      Min.nchar: 1       Min.nchar:10
 3rd Qu.:1    3rd Qu.:60   Max.nchar: 3      Max.nchar: 1       Max.nchar:10
 Max.   :1    Max.   :60
 Unidades_Matriculadas Localidad_definitiva Provincia_definitiva Codigo_Postal      Viviendas
 Min.   :0             Length   :83         Length   :83         Min.   :0.0280   Min.   :0.1132
 1st Qu.:0             N.unique : 3         N.unique : 2         1st Qu.:0.0280   1st Qu.:0.1132
 Median :0             N.blank  : 0         N.blank  : 0         Median :0.0280   Median :0.1132
 Mean   :0             Min.nchar: 9         Min.nchar: 5         Mean   :0.1003   Mean   :0.1487
 3rd Qu.:0             Max.nchar:23         Max.nchar: 6         3rd Qu.:0.0297   3rd Qu.:0.1201
 Max.   :0                                                       Max.   :0.4860   Max.   :0.3258
 precio_medio_m2  Peso_vivienda     RAISON_SOCIAL      RUE_SSOC    Edad_Conductor
 Min.   :0.1799   Min.   :2.000   Length   :83    Length   :83   Length   :83
 1st Qu.:0.1799   1st Qu.:2.000   N.unique : 7    N.unique : 7   N.unique :13
 Median :0.4255   Median :3.000   N.blank  : 0    N.blank  : 0   N.blank  : 0
 Mean   :0.3761   Mean   :2.843   Min.nchar:14    Min.nchar:10   Min.nchar:12
 3rd Qu.:0.4255   3rd Qu.:3.000   Max.nchar:32    Max.nchar:35   Max.nchar:14
 Max.   :0.6015   Max.   :4.000
 Numero de Conductores   Antigüedad Anos_Antiguedad Numero_vehiculos_parque Cluster_GamaPotencia
```

```
Min.   :0.00740       Min.   :0    Min.   :0       Min.   :0              Length   :83
1st Qu.:0.02720       1st Qu.:0    1st Qu.:0       1st Qu.:0              N.unique : 1
Median :0.06250       Median :0    Median :0       Median :0              N.blank  : 0
Mean   :0.06731       Mean   :0    Mean   :0       Mean   :0              Min.nchar:22
3rd Qu.:0.10035       3rd Qu.:0    3rd Qu.:0       3rd Qu.:0              Max.nchar:22
Max.   :0.17060       Max.   :0    Max.   :0       Max.   :0
Cluster_Antiguedad    Cluster_Edad
Length   :83       Length   :83
N.unique : 4       N.unique : 1
N.blank  : 0       N.blank  : 0
Min.nchar:20       Min.nchar:14
Max.nchar:20       Max.nchar:14
```